

Informe Sesión 3 - Visión por Ordenador

José María Benítez Rodríguez y Raynel Antonio García Bryan

11 de noviembre de 2025

1. Introducción

El objetivo de esta sesión de laboratorio es familiarizarnos con las técnicas fundamentales de procesamiento digital de imágenes, aplicando filtros espaciales y detectores de características. Durante la práctica se trabaja con filtros de suavizado y detección de bordes (Gaussiano, Sobel y Canny), operadores morfológicos, y detectores de esquinas (Harris y Shi-Tomasi).

Estos algoritmos constituyen la base de tareas más avanzadas dentro de la visión por ordenador, tales como segmentación, extracción de puntos de interés, reconocimiento de objetos o SLAM en robótica. El trabajo se realiza en Python usando las librerías `OpenCV`, `NumPy` y `scikit-image`, implementando algunos métodos desde cero para comprender su funcionamiento interno.

La sesión se divide en tres apartados:

- **Apartado A:** Filtros Gaussianos y detección de bordes (Sobel y Canny).
- **Apartado B:** Operadores morfológicos (erosión y dilatación).
- **Apartado C:** Detectores de esquinas (Harris y Shi-Tomasi).

En este documento se desarrolla el apartado A en detalle, mostrando resultados y conclusiones.

2. Apartado A: Filtrado y detección de bordes

2.1. Introducción

El objetivo de este apartado es estudiar cómo afectan el suavizado y distintos detectores de bordes sobre el conjunto de imágenes proporcionado. Se aplican tres tratamientos principales:

- **Filtro Gaussiano:** reduce ruido para facilitar la detección de contornos significativos.
- **Sobel:** operador basado en gradientes para resaltar cambios de intensidad.
- **Canny:** detector avanzado que incluye supresión de no máximos y doble umbral.

El flujo de procesamiento seguido es el siguiente:

$$\textit{Imagen original} \rightarrow \textit{Suavizado Gaussiano} \rightarrow \textit{Sobel / Canny}$$

2.2. Suavizado Gaussiano

Se aplicó un filtro Gaussiano como etapa previa para reducir el ruido de alta frecuencia y mejorar la calidad de los bordes detectados posteriormente.



(a) Gauss 000



(b) Gauss 001



(c) Gauss 002



(a) Gauss 003



(b) Gauss 004



(c) Gauss 005


Figura 2: Resultados del suavizado Gaussiano.

El filtrado permite atenuar ruido y detalles irrelevantes, favoreciendo que los detectores se centren en transiciones de intensidad significativas.


2.3. Detector de bordes Sobel

Se evaluó el operador Sobel en dos escenarios: con y sin suavizado previo, con el fin de analizar la influencia del ruido en la detección de gradientes.


2.3.1. Sobel sin suavizado



(a) Unfiltered 000



(b) Unfiltered 001



(c) Unfiltered 002




Figura 4: Resultados de Sobel sin filtro Gaussiano.

Sin suavizado, los bordes aparecen con ruido elevado y con menor precisión estructural.

2.3.2. Sobel con suavizado Gaussiano




Figura 6: Resultados de Sobel con suavizado previo.

Con el suavizado previo, los gradientes detectados son más estables, uniformes y menos contaminados por ruido.

2.4. Detector de bordes Canny

Canny incorpora filtrado, cálculo de gradientes, supresión de no-máximos y umbralización por histéresis, obteniendo bordes finos, conectados y bien definidos.




Figura 8: Resultados del detector Canny.

Comparativamente, Canny genera bordes más limpios y conectados que Sobel, especialmente cuando existe ruido.

2.5. Comparación con detectores de scikit-image




Figura 9: Comparativa entre detectores.

Se observa que Prewitt es menos sensible al ruido que Sobel, pero menos preciso en diagonales. Sobel detecta bien gradientes, pero depende mucho del suavizado previo. Canny ofrece el mejor equilibrio general entre continuidad, limpieza y precisión.

2.6. Conclusiones del Apartado A

A lo largo del análisis se ha comprobado que el preprocesamiento es clave para lograr una detección de bordes confiable. El filtro Gaussiano es esencial para suprimir ruido previo al cálculo de gradientes, ya que su ausencia provoca detecciones inestables y falseadas, como ocurre claramente en Sobel sin suavizado. Cuando se introduce el suavizado, Sobel mejora notablemente, aunque aún presenta bordes más gruesos y discontinuos en comparación con Canny.

El detector de Canny demuestra ser el más robusto del conjunto evaluado, generando contornos finos, continuos y limpios gracias a su combinación de supresión no máxima y doble umbral adaptativo. Esto lo posiciona como la técnica más adecuada para este conjunto de imágenes.

En consecuencia, el flujo de procesamiento óptimo determinado tras los experimentos es:

Imagen Original → Suavizado Gaussiano → Detección Canny

3. Apartado B: Operaciones Morfológicas

3.1. Introducción

Tras obtener los mapas de bordes, en esta sección aplicamos operaciones morfológicas para modificar la estructura de las regiones detectadas y analizar cómo afectan a la forma, continuidad y grosor de los bordes.

Las transformaciones utilizadas son:

- **Erosión:** contrae los objetos eliminando píxeles en los bordes.
- **Dilatación:** expande los objetos, aumentando el grosor de las regiones blancas.

El objetivo es observar cómo estas operaciones afectan a los mapas de bordes y entender qué transformaciones ayudan a mejorar la conectividad o la limpieza de ruido.

3.2. Dilatación

La dilatación añade píxeles a los bordes detectados, lo que suele rellenar huecos y engrosar contornos.

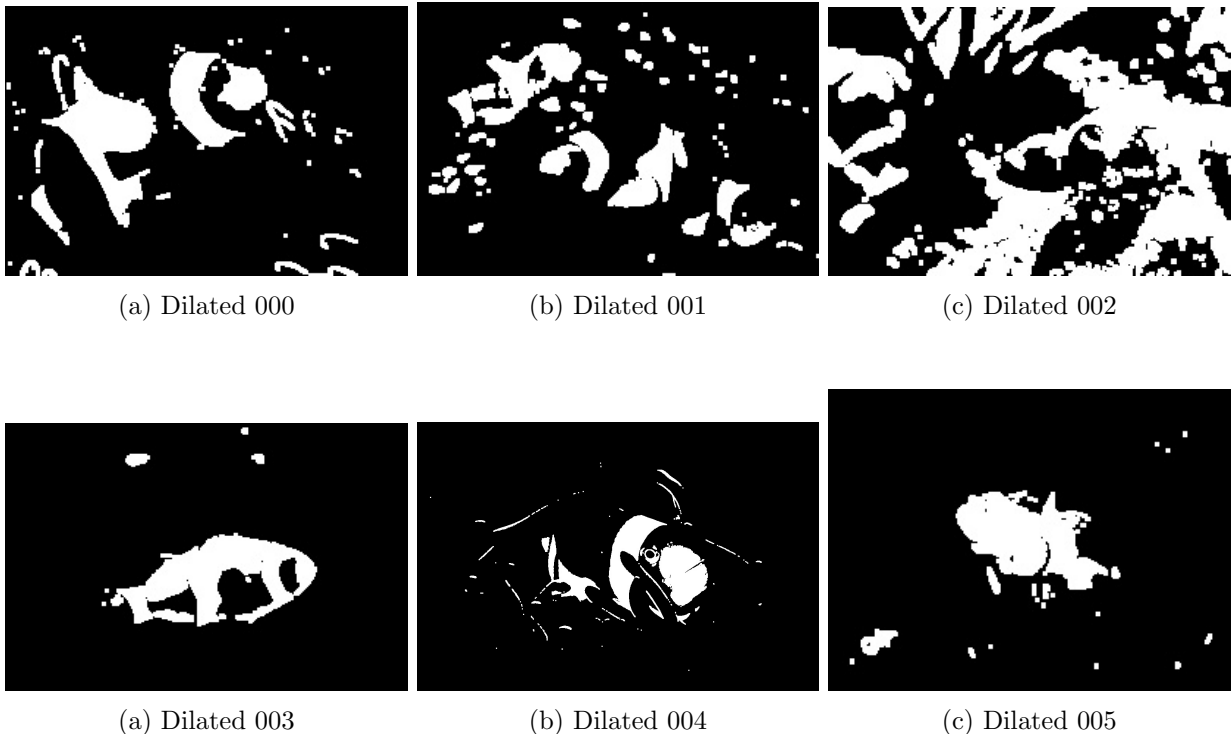


Figura 11: Resultado tras aplicar dilatación.

Tras aplicar la dilatación sobre los bordes detectados, se observa que se corrigen discontinuidades en los contornos, logrando que líneas previamente fragmentadas aparezcan conectadas. Como consecuencia, los bordes resultantes presentan un mayor grosor, lo que puede facilitar su detección

posterior en procesos que requieran regiones más sólidas. Sin embargo, este aumento de espesor también puede provocar la unión de regiones originalmente separadas, lo cual puede resultar beneficioso en algunos casos como cuando se busca cerrar contornos, pero contraproducente en otros donde se necesita mantener los objetos claramente diferenciados.

3.3. Erosión

La erosión elimina píxeles del contorno, reduciendo el grosor de los objetos detectados.




Figura 13: Resultado tras aplicar erosión.

Tras aplicar la erosión, se observa que esta operación morfológica es eficaz para eliminar ruido aislado y reducir elementos de pequeño tamaño que no forman parte de la estructura principal de la imagen. Sin embargo, su uso debe ser controlado, ya que una aplicación excesiva puede provocar la fragmentación de regiones que originalmente estaban conectadas, afectando a la continuidad de los contornos. Por tanto, la erosión resulta especialmente útil para limpiar artefactos o eliminar detalles no relevantes, pero puede ser contraproducente en escenarios donde se requiere preservar la integridad y la conexión entre bordes o regiones.

3.4. Conclusiones del Apartado B

Tras analizar los efectos de las operaciones morfológicas, se observa que tanto la dilatación como la erosión aportan ventajas específicas, pero también limitaciones que deben tenerse en cuenta según el propósito de uso. La dilatación favorece la conectividad entre bordes, siendo especialmente útil cuando existen discontinuidades o contornos fragmentados; sin embargo, este beneficio se obtiene a costa de una pérdida de precisión, ya que los bordes se ensanchan y pueden llegar a fusionar regiones próximas que originalmente estaban separadas.

Por otro lado, la erosión actúa como un filtro eficaz para reducir ruido y eliminar pequeñas regiones no deseadas, pero si se aplica de manera agresiva puede provocar la ruptura de contornos relevantes, afectando a la continuidad estructural de la imagen. Por ello, la selección entre una u otra operación depende directamente del objetivo perseguido: si el propósito es reforzar la unión entre bordes, la dilatación es la operación más adecuada, mientras que si se prioriza la eliminación de ruido o artefactos, la erosión ofrece mejores resultados.

Finalmente, se concluye que, aunque la dilatación permite reconectar bordes y la erosión resulta clave para la limpieza visual, ambas deben aplicarse con moderación para evitar la degradación estructural de los objetos. En escenarios donde se requiere un balance entre ambas mejoras, el uso combinado de operaciones morfológicas (como apertura o cierre) se presenta como una alternativa adecuada a explorar en futuras etapas del procesamiento.

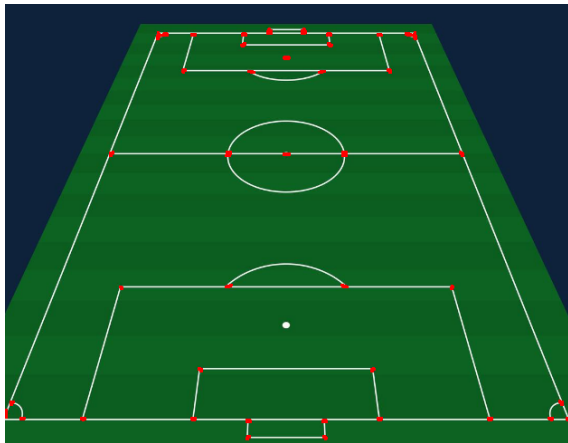
4. Apartado C: Detección de esquinas

4.1. Introducción


En este apartado se aborda la detección de esquinas en distintas imágenes utilizando dos detectores clásicos: **Harris** y **Shi–Tomasi**. El propósito es analizar cómo localizan puntos de interés geoméricamente relevantes y evaluar su comportamiento ante distintos escenarios visuales, comparando su estabilidad, precisión y grado de control sobre el número de esquinas detectadas.

4.2. Detección de esquinas


4.2.1. Detector Harris




(a) Harris Football



(b) Harris Geometry



(a) Harris Tennis




(b) Harris Sudoku

Figura 15: Resultados del detector Harris.


Observaciones:

- Localiza correctamente esquinas en estructuras angulares definidas, como formas geométricas y cuadrículas.
- Tiende a detectar un número elevado de puntos, especialmente en áreas texturizadas o con ruido visual.
- No permite establecer un número máximo de esquinas a detectar, lo que reduce el control sobre el resultado final.


4.2.2. Detector Shi-Tomasi




(a) Shi-Tomasi Football



(b) Shi-Tomasi Geometry



(a) Shi-Tomasi Tennis



(b) Shi-Tomasi Sudoku

Figura 17: Resultados del detector Shi-Tomasi.

Observaciones:

- Permite limitar el número máximo de esquinas detectadas, ofreciendo mayor control sobre el resultado.
- Prioriza las esquinas de mayor calidad, descartando puntos redundantes o poco representativos.
- Muestra mayor estabilidad en escenas con ruido o texturas irregulares, como césped o fondos complejos.

4.3. Conclusiones del Apartado C

Tras realizar el análisis comparativo, se observa que ambos detectores son capaces de identificar esquinas relevantes en estructuras bien definidas, como figuras geométricas o patrones regulares. No obstante, el detector de Harris tiende a generar un número elevado de puntos de interés, especialmente en imágenes con ruido o textura compleja, lo que dificulta seleccionar únicamente los puntos más relevantes y reduce el nivel de control sobre la salida del algoritmo.

Por el contrario, Shi-Tomasi ofrece resultados más consistentes y manejables, ya que permite establecer un número máximo de esquinas a detectar, priorizando además las más representativas según el valor propio mínimo del gradiente local. Esto se traduce en un conjunto de características más estable, compacto y robusto ante variaciones de textura y ruido.

Por tanto, se concluye que, si bien Harris es útil para localizar una gran cantidad de esquinas potenciales, Shi-Tomasi resulta más adecuado para aplicaciones prácticas en las que se requiere precisión, estabilidad y control sobre el número de puntos de interés detectados.